

# **Predicción de productividad laboral en la industria textil a partir de información del proceso manufacturero empleando cuatro (4) técnicas de Inteligencia Artificial**

Manuel Andrés Paz Castillo.<sup>1</sup> Israel Steven Orozco Rodríguez.<sup>1</sup>

<sup>1</sup> Pontificia Universidad Javeriana, Bogotá CO 110231, Colombia

**Palabras Clave:** Productividad, Predicción, Experimentación, Redes Neuronales, Algoritmos Genéticos, Lógica Difusa, Machine Learning.

## **1 Motivación y Contextualización del Problema**

La industria textil es uno de los sectores más representativos de la globalización actual. Alrededor del mundo, esta actividad es altamente intensiva en el uso de fuerza laboral debido a la gran cantidad de actividades manuales que persisten en el proceso de producción. Los retos que impone la demanda masiva mundial de prendas de vestir hacen que la productividad laboral sea un elemento clave en el éxito económico de las compañías relacionadas. En este sentido, el uso de técnicas de Inteligencia Artificial para predecir esta variable, son altamente recomendadas para potencializar el uso de la mano de obra y por ende, los beneficios económicos derivados.

Dentro de estos beneficios, entre otros, se encuentran, reducción de costos, reorganización de las cadenas productivas, identificación de falencias o factores que debilitan la productividad, optimización de las tareas asignadas.

Para tal fin se desarrollan modelos con base en las técnicas de Inteligencia Artificial de Redes Neuronales, Algoritmos Genéticos, Lógica Difusa y Machine Learning, que son comparados a nivel experimental con base en medidas de desempeño y precisión para determinar la mejor aproximación metodológica y fáctica.

## 2 Descripción de la Tarea

Para estimar con precisión la producción laboral en una industria manufacturera, se propone trabajar modelos de predicción con las siguientes etapas: (i) descripción de la base de datos; (ii) identificación de etiquetas relevantes sobre la información disponible; (iii) codificación de etiquetas identificadas; (iv) estandarización y depuración de datos; (v) particionamiento entre conjunto de datos de entrenamiento y conjunto de validación; (vi) definición de la arquitectura del modelo (incluido algoritmo de optimización); (vii) aplicación de protocolos de experimentación; (viii) evaluación de desempeño con base en métricas de desempeño; (ix) definición de línea base para comparación; (x) análisis de resultados y análisis comparativo entre diferentes metodologías.

La base de datos escogida es “Productivity Prediction of Garment Employees Data Set” disponible en el repositorio de Machine Learning UCI (ver <https://archive.ics.uci.edu/ml/datasets/Productivity+Prediction+of+Garment+Employees>).

Esta base de datos es de serie de tiempo multivariada con un total de 15 atributos y 1.197 entradas que puede ser utilizada con propósitos de regresión o clasificación.

Los atributos están descritos en la siguiente tabla:

01	Fecha
02	Día
03	Trimestre
04	Departamento
05	Número de Equipo
06	Número de Trabajadores
07	Número de cambios de cierto producto.
08	Meta de productividad por cada equipo y cada día.
09	Valor estándar del minuto.
10	Trabajo en proceso.
11	Minutos de sobrepaso de tiempo meta.
12	Cuantía del Incentivo Financiero
13	Tiempo de interrupción en producción.
14	Número de trabajadores inactivos por interrupciones.
15	Porcentaje de productividad actual

La información de la base de datos recién descrita compone, pese a los valores faltantes, información suficiente para la segmentación en conjuntos de entrenamiento y validación. Adicionalmente, es ventajosa la posibilidad de adelantar

ejercicios tanto de regresión como de clasificación. Una restricción sería una heterogeneidad en las unidades de medida de los diferentes atributos. No obstante, consideramos que pueden resolverse a partir de técnicas de normalización y estandarización.

### 3 Potencialidad Uso de Herramientas de IA

El equipo del proyecto pudo determinar que el problema definido y la información relacionada disponible, tanto por su cantidad, como su número de atributos y propósito general, permiten la aplicación de herramientas de inteligencia artificial, protocolos de experimentación y validación de resultados. Aunado a lo anterior, esta última etapa para los modelos que serán propuestos, permitirán realizar un análisis comparativo con base en métricas de desempeño aplicados a diferentes ejercicios de experimentación, de tal forma que puedan generarse conclusiones.

Sumado a lo anterior, el equipo pudo establecer la existencia de diferentes ejercicios con técnicas particulares y bases similares que buscaban estimar la productividad laboral en sectores de manufactura, esto para identificar posibilidades de optimización y por ende, los resultados económicos de las industrias analizadas (Imran, A. et al. 2019) (Rahim, M. et al. 2021) (Alican, D. et al. 2021).

### 4 Viabilidad Validación Experimental

Los modelos de Inteligencia Artificial serán aplicados sobre datos reales tomados de Industrias Manufactureras e ilustradas en la sección de “Descripción de la Tarea”. Aunado a lo anterior, de conformidad con las secciones anteriores, el equipo determinó casos de aplicación de protocolos experimentales a la misma problemática con bases de datos similares, por lo cual se puede establecer la factibilidad de aplicación con la problemática identificada de los datos encontrados.

Por la configuración del problema, siendo este de predicción, se proponen las siguientes métricas para la validación experimental:

Nombre	Descripción	Cálculo
--------	-------------	---------

Mean Squared Error -MSE.	Mide el error cuadrático medio de las predicciones realizadas.	$MSE = 1/N \sum_{t=1}^n (y_i - \hat{y}_i)^2$
<i>Mean Absolute Error -MAE-</i>	Es el promedio de las diferencias absolutas entre los valores reales y sus predicciones.	$MAE = \frac{1}{N} \sum_{t=1}^n  y_i - \hat{y}_i $
Mean Absolute Percentage Error -MAPE-	Es una expresión porcentual del error relativo.	$MAPE = \frac{100\%}{N} \sum_{t=1}^n \left  \frac{y_i - \hat{y}_i}{y_i} \right $

## 5 Referencias

- [1] A. Imran, M. Amin, M. Islam and S. Mehreen, "Deep Neural Network Approach for Predicting the Productivity of Garment Employees," *International Conference on Control, Decision and Information Technologies (CoDIT)*, 2019.
- [2] M. Rahim, A. Imran and T. Ahmed, "Mining the Productivity Data Garment Industry.," *International Journal of Business Intelligence and Data Mining*, 2021.
- [3] A. Dogan, D. Birant "Machine Learning and Data Mining in Manufacturing," *T-Re*, vol. 8, (3), pp. 305-311, 2021.

[