

# Predicción de productividad laboral en la industria textil a partir de información del proceso manufacturero empleando Redes Neuronales

Manuel Andrés Paz Castillo.<sup>1</sup> Israel Steven Orozco Rodríguez.<sup>1</sup>

<sup>1</sup> Pontificia Universidad Javeriana, Bogotá CO 110231, Colombia

**Resumen.** La industria textil es uno de los sectores más representativos de la globalización actual. Los retos que impone la demanda masiva mundial de prendas de vestir hacen que la productividad laboral sea un elemento clave en el éxito económico de las compañías relacionadas. En este sentido, el uso de técnicas de Inteligencia Artificial para predecir esta variable, son altamente recomendadas para potencializar el uso de la mano de obra y por ende, los beneficios económicos derivados. Dentro de estos beneficios, entre otros, se encuentran, reducción de costos, reorganización de las cadenas productivas, identificación de falencias o factores que debilitan la productividad, optimización de las tareas asignadas. Para tal fin se desarrollan diferentes modelos de Redes Neuronales que muestran una precisión en el mejor de los casos del 0,01925 según la métrica de MSE.

**Palabras Clave:** Productividad, Predicción, Experimentación, Redes Neuronales, Experimentación.

## 1 Introducción

Alrededor del mundo, esta actividad es altamente intensiva en el uso de fuerza laboral debido a la gran cantidad de actividades manuales que persisten en el proceso de producción. Las métricas de productividad, en este sentido, juegan un papel fundamental en los procesos de optimización de costos asociados a las cadenas de producción textil a nivel mundial.

La información de productividad laboral en la industria textil utilizada en el presente documento es tomada de forma manual y verificada con posterioridad por parte de expertos especializados en el campo. Es usual que dicha información considere atributos adicionales como la utilización de incentivos financieros, el tamaño de los equipos, la discriminación de demoras o fallas en el proceso manufacturero, el número de empleados afectados por la paralización de actividades previas o incluso el número de cambios recientes aplicados al producto final.

En el presente trabajo, se muestra la implementación de un algoritmo de predicción utilizando redes neuronales artificiales para la estimación de la productividad laboral en la industria textil. Con el fin de llevar a cabo un experimento controlado, se selecciona y particiona la base de datos entre un conjunto de experimentación (70%) y un conjunto de validación (30%) y se implementa un protocolo experimental que ajusta el número de neuronas de entrada, el número de capas ocultas y las funciones de activación utilizadas con el objetivo de medir el desempeño comparado y concluir sobre el mejor modelo para la predicción de la variable de interés.

## **2 Estado del arte**

Actualmente, la investigación en métodos supervisados de inteligencia artificial en el campo de la manufactura versa sobre la predicción y eliminación de defectos y fallas en la industria del acero [1], la predicción de variables productivas globales basada en modelos de redes neuronales [2], el control de procedimientos manufactureros [3], y estimaciones de calidad de producto basados en la detección temprana de fallas internas de materiales insumo [4].

En particular, el estado del arte en el uso de redes neuronales para la predicción de la productividad actual de los empleados muestra la adopción de redes profundas multicapa y uso de capas ocultas con altos resultados de predicción en métricas como el error absoluto medio. Para tal fin, es fundamental la definición del número de neuronas de entrada y salida, el número de capas ocultas, las funciones de activación utilizadas, el algoritmo de optimización implementado, las tasas de aprendizaje, la composición de los conjuntos de entrenamiento y validación, así como el número de epochs. Los trabajos relacionados hasta el momento muestran una alta utilidad en la utilización de variables diversas para la predicción de la productividad como las fechas de generación, los números y composiciones de cada equipo, las metas de productividad establecidas por la compañía y los resultados de la productividad actual [5].

### **2.1 Deep Neural Network Approach for Predicting the Productivity of Garment Employees. Imran, et al. 2019.**

Este documento presenta una propuesta metodológica para la estimación de la productividad laboral en la industria textil a partir de modelos de redes de aprendizaje profundo con la utilización de protocolos de experimentación. Para tal fin, hace uso de los datos tomados del departamento de ingeniería industrial de una empresa textil en Bangladesh para el periodo considerado entre enero y marzo de 2015. La base de datos contó con un total de 13 atributos y 1.197 entradas.

Durante el desarrollo del modelo, los autores utilizaron un conjunto de entrenamiento equivalente al 80% de la base de datos, otro 10% para validación y otro 10% para testeo. A continuación, la arquitectura de la red utilizada por los autores:




Fig. 1. DNN Architecture.

Como se puede observar en la ilustración anterior, el documento presenta un total de 30 neuronas en la capa de entrada, dos (2) capas ocultas, una capa de salida con una única neurona por ser un ejercicio de predicción, y la utilización de dos (2) funciones de activación, siendo éstas la función ReLU y la función Sigmoide. Adicionalmente, como algoritmo de optimización, los autores proponen el Estimador Adaptativo de Momentos (Adam, por sus siglas en inglés).

De acuerdo con el documento en mención, con base en las métricas de evaluación Mean Squared Error -MSE-, Mean Absolute Error -MAE- y Mean Absolute Percentage Error -MAPE-, los autores concluyeron que los resultados de validación eran bastante similares a los datos de testeo, lo cual implica que el modelo tiene una capacidad de aprendizaje sustancial sin presentar indicios de sobre-especificación. Como resultado, los autores establecen que el modelo propuesto cuenta con un desempeño predictivo que muestra un error de predicción del 0,086, significativamente menor que la línea base y por tanto, significativamente útil para predecir la productividad laboral en una empresa de la industria textil.

### 3 Metodología

A continuación, se describen los métodos empleados para la composición de redes neuronales para la predicción de la productividad laboral en la industria textil con base en la información disponible y en un protocolo experimental. Se comienza estableciendo una arquitectura inicial de la red neuronal seguido a la definición de las métricas de evaluación.

### 3.1 Descripción de la base

Con el fin de llevar a cabo la implementación, se tomó la base de datos pública “*Productivity Prediction of Garment Employees Data Set*” [6] del repositorio de machine learning UCI. La base de datos es de serie de tiempo multivariada compuesta por 15 atributos y 1.197 entradas que puede ser utilizada con propósitos de regresión o clasificación.

Los atributos, están descritos en la siguiente tabla.

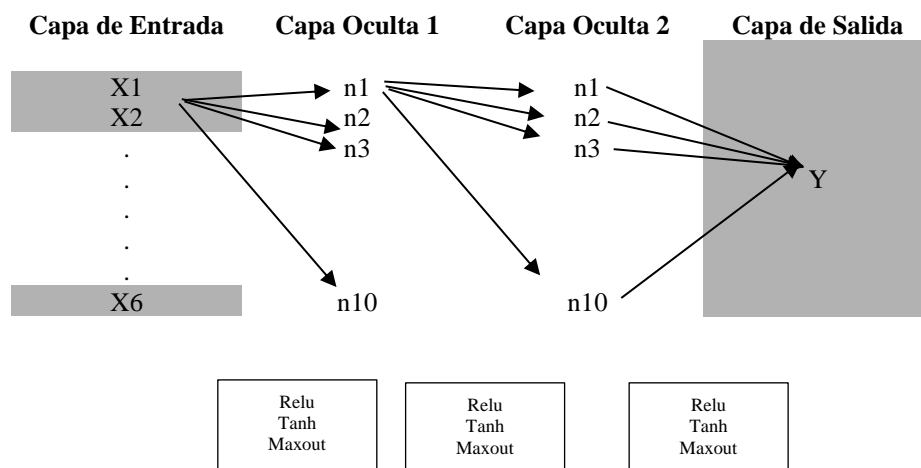
Número	Descripción
01	Fecha
02	Día
03	Trimestre
04	Departamento
05	Número de Equipo
06	Número de Trabajadores
07	Número de cambios de cierto producto.
08	Meta de productividad por cada equipo y cada día.
09	Valor estándar del minuto.
10	Trabajo en proceso.
11	Minutos de sobrepaso de tiempo meta.
12	Cuantía del Incentivo Financiero
13	Tiempo de interrupción en producción.
14	Número de trabajadores inactivos por interrupciones.
15	Porcentaje de productividad actual

### 3.2 Arquitectura de la Red Neuronal

El diseño de una red neuronal está basado en la definición de un subconjunto de hiper parámetros que pueden variar para mejorar la capacidad predictiva de los modelos. Dentro de estos pueden encontrarse el número de capas ocultas, el número de neuronas de entrada y de salida, las funciones de activación utilizadas, el algoritmo de optimización implementado, la tasa de aprendizaje, el tamaño de los conjuntos de aprendizaje y validación, entre otros.

Durante el proceso de elaboración del modelo, se realizó un proceso de depuración de variables que no contribuían efectivamente a los procesos de estimación y predicción de productividad laboral. Como resultado de este proceso, los seis (6) atributos finalmente seleccionados fueron: (i) Número de equipo; (ii) Número de trabajadores por equipo; (iii) valor estándar del minuto; (iv) Trabajo en proceso; (v) minutos de sobrepaso de tiempo meta; y (vi) cuantía del incentivo financiero.

A continuación, se presenta el diseño de la red neuronal propuesta en el presente documento.



Para el modelo propuesto, el conjunto de entrenamiento está compuesto por el 70% de los datos de la base original. El 30% restante, refiere al conjunto utilizado en el proceso de validación y testeo. En la capa de entrada, se utilizaron un total de 6 neuronas, mientras que para la salida, por ser un proceso de predicción, solo contamos con una neurona. En cada capa oculta fueron utilizadas entre 1 y 10 neuronas. En cada proceso, fue utilizada una función de activación, la cual varió entre una ReLU, una Tangente Hiperbólica y una MaxOut.

Las neuronas de entrada corresponden a los atributos restantes del proceso de depuración de la base de datos. Siendo estos, número de equipo, número de trabajadores por equipo, valor estándar del minuto, trabajo en proceso, minutos de sobrepaso de tiempo meta, y cuantía del incentivo financiero.

La neurona de salida corresponde a la productividad laboral estimada por cada modelo utilizando las metodologías y arquitectura mencionadas.

La definición del número de capas ocultas, representa uno de los elementos más importantes de la configuración de una red neuronal. De acuerdo con Jeff Heaton [7], una única capa oculta puede aproximar cualquier función que configure un mapeo continuo desde un espacio finito hacia otro. Por su parte, la utilización de dos capas ocultas puede representar un “suavizamiento” del mapeo para cualquier nivel de precisión. En el caso presente, al igual que en modelos más generales, la utilización de más de dos capas ocultas puede complejizar el modelo y hacerlo ineficiente desde la perspectiva computacional.

Como funciones de activación, fueron utilizadas las funciones ReLU, Tangente Hiperbólica y MaxOut. Estas funciones, permiten realizar los mapeos funcionales que relacionan las entradas con la variable de salida. Estas funciones toman la señal de input en un nodo y la transforman en una señal de output. Aunado a lo anterior, estas funciones permiten hacer que las redes neuronales sean no lineales. A continuación, una breve descripción de las funciones implementadas en el presente documento:

### **Rectified Linear Unit (ReLU)**

La función ReLU es una de las funciones de activación más comunes utilizadas en redes neuronales. La función devuelve 0 si recibe cualquier entrada negativa. Para cualquier valor positivo  $x$ , la función retorna valores regidos por:

$$f(x) = \max(0, x)$$

En este caso,  $x$  es la entrada de una neurona. La función ReLU es usualmente simple de calcular, cuenta con un comportamiento lineal en cuando a rendimiento y acciones, por lo cual optimiza con mayor facilidad que otras funciones. Adicionalmente, esta función permite con cierta facilidad la consideración de comportamientos e interacciones no lineales.

### **Tangente Hiperbólica -TanH**

La función Tangente Hiperbólica es una función cuya salida está entre -1 y 1 con derivadas entre 0 y 1. Entre mayor es la entrada (más positiva), el valor de salida estará más cerca a 1, mientras que en caso contrario, la salida estará más cercada a -1. La función está dada por:

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

El comportamiento de la función Tangente Hiperbólica es muy similar a la de la función Sigmoide.

### **MaxOut**

La función de activación MaxOut está definida por la siguiente expresión:

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

Esta función es una generalización de las funciones ReLU y ReLU con fugas, en la que cuenta con una base lineal de funcionamiento sin los inconvenientes que puedan tener las funciones básicas de ReLU. Una posible desventaja es la duplicación del número de parámetros para cada neurona.

### 3.3 Algoritmo de Optimización

En redes neuronales, el algoritmo de optimización juega un papel esencial en el desempeño de cualquier modelo estimado, especialmente con relación a los resultados de desempeño establecidos. Este algoritmo permite conformar el modelo con la mejor forma posible con base en el ajuste dinámico de los pesos.

En el presente documento, hacemos uso del método descenso de gradiente. Este método, permite estimar numéricamente el punto en donde una función de pérdida o costo genera sus valores más bajos. Esto lo realiza a través del tanteo dinámico de puntos y la evolución de la pendiente de la recta tangente relacionada. Con base en una tasa de aprendizaje pre-definida, el algoritmo busca puntos que satisfagan las condiciones y las plantea como posibilidades de punto óptimo. Es importante resaltar que la elección de la tasa de aprendizaje es fundamental en el desempeño del modelo, pues una muy baja puede generarnos un alto costo computacional, mientras que una tasa alta puede llevarnos a “saltar” puntos óptimos. En el documento presente, utilizamos una tasa de aprendizaje de  $1e-8$ .

### 3.4 Métricas de desempeño:

Por la configuración del problema, siendo este de predicción, el presente documento propone utilizar, como elementos de valoración de desempeño predictivo del modelo, las métricas MSE y MAE. La siguiente tabla muestra la descripción de cada una:

Nombre	Descripción	Cálculo
Mean Squared Error -MSE.	Mide el error cuadrático medio de las predicciones realizadas.	$MSE = 1/N \sum_{t=1}^n (y_i - \hat{y}_i)^2$
Mean Absolute Error -MAE-	Es el promedio de las diferencias absolutas entre los valores reales y sus predicciones.	$MAE = \frac{1}{N} \sum_{t=1}^n  y_i - \hat{y}_i $

### 3.5 Implementación de Redes Neuronales

Una vez se ha definido la arquitectura de la red neuronal propuesta, se procede a implementar el modelo con diferentes variaciones experimentales en el Software de cómputo RapidMiner Studio.

### 3.6 Protocolo experimental

La validación experimental es adelantada con seis (6) de los 15 atributos considerados, con el objetivo de determinar la precisión en el pronóstico.

El experimento incluye el ensayo y ejecución de la red neuronal aplicando variaciones en el número de capas ocultas (entre una y dos), número de neuronas por cada capa oculta (entre una y diez) y función de activación específica (entre ReLU, Tangente Hipérbólica o MaxOut).

Cada ejecución comprende el recorrido entre entrenamiento, validación y prueba entre 1.197 registros, distribuidos 70% y 30% respectivamente.



## 4 Resultados

De conformidad con los resultados obtenidos y en línea con las métricas de desempeño utilizadas, los siguientes son los resultados por cada función de activación utilizada, según el número de capas ocultas, y el número de neuronas implementadas.

### Función de Activación ReLU

#### 1 Capa Oculta



#Neuronas	MSE Prom	MAE Prom
1	0,029333	0,134226
2	0,022494	0,111563
3	0,022185	0,110607
4	0,021308	0,107702
5	0,020988	0,10692
6	0,020396	0,107482
7	0,01956	0,107631
8	0,019341	0,102636
9	0,019232	0,102451
10	0,019213	0,102825





## 2 Capas Ocultas



#Neuronas	MSE Prom	MAE Prom
1	0,028941	0,13179
2	0,024438	0,118863
3	0,02259	0,114559
4	0,020307	0,10781
5	0,019949	0,104989
6	0,019614	0,104655
7	0,019137	0,101053
8	0,019332	0,102262
9	0,01899	0,100959
10	0,020144	0,105331



## Función de Activación TanH



### 1 Capa Oculta

#Neuronas	MSE Prom	MAE Prom
1	0,023542	11,77%
2	0,020895	10,83%
3	0,020305	10,74%
4	0,020243	10,69%
5	0,020194	10,62%
6	0,01978	10,52%
7	0,019663	10,43%
8	0,019264	10,37%
9	0,019405	10,37%
10	0,019273	10,28%



### 2 Capas Ocultas


#Neuronas	MSE Prom	MAE Prom
1	0,023538	11,73%
2	0,02126	10,94%
3	0,01999	10,74%
4	0,019937	10,61%
5	0,01945	10,42%
6	0,018881	10,13%
7	0,018966	10,18%
8	0,018906	10,13%
9	0,018752	10,06%
10	0,019643	10,44%



## Función de Activación MaxOut


### 1 Capa Oculta

#Neuronas/1 capa Oculta	MSE Prom	MAE Prom
1	0,028726	13,2%
2	0,024605	11,4%
3	0,023398	11,4%
4	0,022948	11,2%
5	0,020581	10,6%
6	0,020291	10,4%
7	0,01925	10,2%
8	0,019239	10,1%
9	0,01929	10,1%
10	0,018791	10,0%



### 2 Capas Ocultas

#Neuronas/ 2 capas	MSE Prom	MAE Prom
1	0,030675	13,74%
2	0,025327	12,17%
3	0,022903	11,33%
4	0,020821	10,74%
5	0,019581	10,45%
6	0,019158	10,03%
7	0,018254	9,78%
8	0,018732	9,89%
9	0,019083	10,00%
10	0,01975	10,35%



## 5 Conclusiones

- El uso de técnicas de Inteligencia Artificial para predecir la productividad laboral, son altamente recomendadas para potencializar el uso de la mano de obra y por ende, los beneficios económicos derivados en la industria textil.
- La arquitectura en las redes neuronales es fundamental para un desempeño adecuado del modelo.
- Las métricas de desempeño de predicción más utilizadas son Mean Squared Error (MSE) y Mean Absolute Error -MAE-.
- El protocolo experimental permite evaluar el desempeño adecuado de los modelos, además de determinar la utilidad final de cada herramienta.
- Diferentes técnicas de Redes Neuronales han mostrado su utilidad en la predicción de la productividad laboral en la industria manufacturera.
- En particular, el estado del arte en el uso de redes neuronales para la predicción de la productividad actual de los empleados muestra la adopción de redes profundas multicapa y uso de capas ocultas con altos resultados de predicción en métricas como el error absoluto medio.

- El modelo propuesto integrado por 6 neuronas en capa de entrada, dos capas ocultas, y una capa de salida con una única neurona por ser modelo predictivo, en conjunto con las funciones de activación utilizadas en el protocolo experimental, permiten contar con una buena herramienta para estimar la productividad laboral en la industria textil.
- En particular, según las métricas de desempeño establecidas, los mejores modelos utilizan funciones de activación MaxOut con dos capas ocultas y 7 neuronas cada una.

## 6 Referencias

- [1] X. Zhang, M. Kano, M. Tani, J. Mori, J. Ise, K. Harada, "Prediction and causal analysis of defects in steel products: Handling nonnegative and highly overdispersed count data," *Control Engineering Practice*, 2019.
- [2] R. Ferreira, A. Sabbaghi, Q. Huang, "Automatic geometric shape deviation modeling for additive manufacturing systems via Bayesian neural networks" *IEEE Transactions on Automation Science and Engineering*, 2020.
- [3] E. Alfaro-Cortes, J. Alfaro-Navarro, M. Gamez, N. García, "Using random forest to interpret out-of-control signals" *Acta Polytechnica Hugarica*, 2020.
- [4] J. Forero-Ramirez, A. Restrepo-Giron, S. Nope-Rodríguez, "Detection of internal defects in carbon fiber reinforced plastic slabs using background thenmal compensation by filtering and support vector machines" *Journal of Nondestructive Evaluation*, 2019.
- [5] M. Rahim, A. Imran and T. Ahmed, "Mining the Productivity Data Garment Industry.," *International Journal of Business Intelligence and Data Mining*, 2021.
- [6] UCI Machine Learning Repository "Productivity Prediction of Garment Employees Data Set", Disponible en <https://archive.ics.uci.edu/ml/datasets/Productivity+Prediction+of+Garment+Employees> 2020.
- [7] J. Heaton, "Introduction to neural networks with Java" *Heaton Research*, 2008.